

Context Saver 1.0 — guia completo

Documentação técnica e operacional

Nós provider-neutral para reduzir contexto, preservar fatos críticos e recuperar detalhes exatos sob demanda.

Resultado

Context Saver reduz os tokens de entrada dos AI Agents sem depender de Gemini, OpenAI, Anthropic, Ollama ou outro provider. Primeiro aplica transformações determinísticas; conteúdo removido do prompt pode continuar armazenado e recuperável.

Não promete uma porcentagem em qualquer entrada. Se uma redução ameaçar fatos, tool calls, structured output ou cache útil, o perfil adaptativo reduz a agressividade ou devolve o original.

Escolha rápida

Problema	Nó principal	Posição
Prompt, histórico e muitas tools em cada chamada	Agent Optimizer	Entre Chat Model e AI Agent
JSON, API, RAG, HTML ou logs grandes	Data Optimizer	Antes do campo de contexto do Agent
Dois ou mais agentes repetindo contexto	Agent Handoff	Entre a saída de um Agent e a entrada do próximo
Conversa longa entre várias execuções	Session Memory	No caminho principal antes do Agent
Original precisa ficar fora do prompt	Context Storage + Exact Lookup	Storage no fluxo; Lookup na porta Tool
Medir a economia da execução	Savings Report	Depois do caminho otimizado

Comece somente com **Agent Optimizer / Balanced**. Adicione outros nós quando o workflow tiver o problema correspondente.

Perfis

Perfil	Redução típica do conteúdo elegível	Uso recomendado
Quality First	15–35%	Código, regras críticas, contratos, structured output
Balanced	35–60%	Padrão para agentes, chat, APIs e RAG
Maximum Savings	60–85%	Tool results grandes com Exact Lookup conectado
Custom	Configurável	Casos avaliados com testes próprios

As faixas não são garantia da fatura completa. O prompt não elegível, a saída do modelo e o cache do provider também influenciam custo real.

1. Agent Optimizer

O que faz

Envolve qualquer Chat Model compatível com LangChain/n8n e otimiza cada chamada do AI Agent. Atua em prompt do sistema, mensagens antigas, resultados de tools e schemas de tools. Preserva a mensagem atual e sequências ativas de tool call/result.

Como ligar

```
text
Chat Model -> Agent Optimizer -> AI Agent
|-> Exact Lookup, quando usar Maximum Savings
```

Campos

Campo	Função
Model	Chat Model original que será envolvido.
Mode	Save Tokens otimiza; Measure Baseline apenas mede para A/B.
Profile	Define janela recente, seleção e alvo de economia.
Adaptive Quality Protection	Rebaixa automaticamente para perfil mais seguro em código, citação exata, structured output, tool forçada, sequência ativa ou recuperação ausente. Mantenha ligado.
Optimize Repeated Prompt Rules	Remove blocos exatamente repetidos no system prompt; não reescreve regras únicas.
Cache Strategy	Automatic Hybrid preserva prefixos estáveis e reduz partes dinâmicas; as outras opções priorizam cache, redução direta ou ignoram sinais.
Tool Schema Selection	Carrega somente schemas claramente relevantes em Maximum Savings. Ambiguidade mantém todas as tools.
Custom Profile	Janela recente, deduplicação aproximada e orçamento manual. Use somente com evals.

Maximum Savings Options

Campo	Função
Storage Provider	Filesystem local/compartilhado ou Redis.
Scope / Session ID / Owner ID	Limites de isolamento. Devem coincidir no Exact Lookup.
Storage Directory / Redis Key Prefix	Local onde o original será encontrado.
Encrypt Stored Content	AES-256-GCM antes de gravar. Requer credencial e chave ≥16 caracteres.
Allow Secret-Like Content Storage	Permite persistir texto parecido com segredo. Desligado por padrão.
Minimum Content Tokens	Abaixo disso, evita virtualização com overhead negativo.
Target Preview (%)	Parte aproximada mantida inline. 20% mira cerca de 80% no conteúdo elegível.
Maximum Preview (%)	Teto do preview; 30% exige ao menos 70% de redução elegível.
Maximum Resource Size (MB)	Limite do original; acima dele faz fallback seguro.
TTL (Hours)	Tempo de recuperação do original.

Tool Schema Selection

Campo	Função
Selection Mode	Automático por perfil, sempre ligado ou desligado.
Minimum Tools Before Selection	Não seleciona conjuntos pequenos.
Maximum Selected Tools	Limite de schemas; tools obrigatórias/ativas podem ultrapassar.
Tool Schema Token Budget	Orçamento estimado total dos schemas.

Campo	Função
Always Available Tool Names	Lista que nunca pode ser removida.

Cache-Aware Options

Campo	Função
Registry Provider	Filesystem ou Redis para fingerprints; não guarda texto do prompt.
Fingerprint Directory	Diretório local de hashes e contadores.
Redis Key Prefix	Namespace compartilhado.
Fingerprint TTL (Hours)	Janela para considerar um prefixo recorrente.
Maximum Fingerprints	Limite local antes de remover observações antigas.
Minimum Repetitions	Repetições antes de tratar prefixo como cacheável.
Minimum Stable Prefix Tokens	Ignora prefixos pequenos, sem ganho relevante.

2. Data Optimizer

O que faz

Reduz conteúdo antes de inseri-lo no prompt. Detecta texto, JSON, HTML, logs, chat, tool output e código. Pode minificar, empacotar arrays JSON em tabela reversível, remover null/vazios autorizados, selecionar campos e virtualizar o restante.

Operações

Operação	Quando usar
Optimize Content	API, RAG, logs, HTML, JSON ou tool output grande.
Build Agent Context	Montar system prompt, memória, mensagem atual, retrieved context e tools em ordem canônica.

Campos de Optimize Content

Campo	Função
Content	Texto/JSON que será otimizado.
Content Type	Auto ou tipo explícito para evitar detecção errada.
Current Task	Consulta usada para projeção e seleção lexical.
Profile	Quality First, Balanced, Maximum Savings ou Custom.
Fields to Include / Exclude	Projeção explícita de campos. Include tem precedência.
Remove Null Fields / Empty Strings	Remove somente valores sem conteúdo quando habilitado.
Protected Values	IDs, frases ou valores que devem sobreviver exatamente.
Quality Verification	Fast, Strict ou Critical; falha volta para candidato mais seguro/original.
Context Virtualization	Disabled, Automatic ou Required.
Output	Simple evita repassar o original; Detailed inclui diagnóstico.

Virtualization Options

Os campos de provider, isolamento, criptografia, tamanho, preview e TTL têm o mesmo significado do Agent Optimizer. **Maximum Preview Items** limita registros/chunks; **Maximum Preview Tokens** limita o preview textual.

Campos de Build Agent Context

Campo	Função
System Prompt	Regras fixas; nunca é misturado semanticamente com dados.
Conversation History	Histórico a compactar.
Current Message	Mensagem atual; preservada completa.
Retrieved Context	Dados recuperados por RAG/tool.
Tool Definitions	Schemas de tools.
Optimization Level / Profile	Política de janela, orçamento e deduplicação.
Keep Recent Messages	Quantidade integral no modo Custom.
Maximum Input Tokens	Alvo; conteúdo único só é cortado se autorizado.
Allow Unique Content Trimming	Permite descarte único no Custom. Arriscado sem Storage/Lookup.
Approximate Deduplication	Une quase duplicados somente com polaridade/negação compatível.
Experimental Semantic Compression	Usa modelo conectado; desligado por padrão.

Semantic Pipeline experimental

LLM Summary, Semantic Deduplication, Task Reranking e LLM Judge geram chamadas extras. Confidence, unit limits e budgets evitam custo descontrolado. Qualquer perda de fatos protegidos causa fallback determinístico.

3. Agent Handoff

O que faz

Cria um contrato compacto entre agentes. Evita enviar toda a conversa e toda a saída do Agent A ao Agent B.

Campos

Campo	Função
Objective	Tarefa exata que o próximo agente continuará.
Source Agent / Destination Agent	Nomes para rastreabilidade.
Confirmed Facts	Fatos com evidência; duplicatas exatas são removidas.
Decisions	Decisões já tomadas.
Pending Actions	Pendências e perguntas abertas.
Recoverable Resource IDs	IDs que o próximo Agent pode consultar pelo Exact Lookup.
Source Output	Saída anterior; sofre packing determinístico quando seguro.
Profile	Intensidade da compactação estrutural.

Quando houver Resource ID válido, Balanced/Maximum Savings podem substituir saída grande por referência recuperável.

4. Session Memory

O que faz

Mantém memória por sessão fora do prompt: fatos fixados, estado atual, resumo incremental, janela recente, valores exatos e referências arquivadas. Detecta atualização de fatos sem tratar valor antigo como atual.

Operações

Operação	Função
Update Session	Aplica novas mensagens/estado e já devolve memoryContext.
Build Context	Monta somente o contexto necessário para o Agent.
Inspect Session	Diagnóstico sem alterar.
Delete Session	Apaga uma sessão.
Purge Expired	Limpa TTL vencido.

Campos

Campo	Função
Storage Provider	Filesystem ou Redis compartilhado.
Session Key	Identificador estável da conversa. Obrigatório.
Scope / Owner ID	Isolamento de workflow/tenant.
New Messages	Mensagens novas, não o histórico completo.
Pinned Facts	Regras/preferências que não devem ser resumidas.
Structured State	Estado atual da tarefa.
State Update Mode	Merge preserva outros campos; Replace substitui o estado.
Incremental Summary	Resumo novo acumulado, sem reprocessar toda a conversa.
Summary Based on Revision	Evita aplicar resumo calculado sobre revisão antiga.
Required Exact Values	IDs/números/frases obrigatórios.
Archived Resource References	Conteúdo antigo recuperável por ID.
Memory Profile / Recent Messages to Keep	Tamanho da janela integral.
Maximum Summary Tokens / Summary Safety	Limite e validação do resumo.
Session TTL / Maximum Session Size	Contenção de storage.
Encrypt Stored Sessions	Criptografia AES-256-GCM.
Output	Simple para Agent; Detailed para auditoria.

Redis usa lock distribuído para atualizações concorrentes. Filesystem é adequado a instância única; queue mode deve usar Redis ou caminho compartilhado.

5. Context Storage

O que faz

Grava o original comprimido fora do prompt, calcula hash, reaproveita recursos iguais e devolve um receipt pequeno.

Operações e campos

Campo	Função
Operation	Store, Inspect, Delete ou Purge Expired.
Content / Content Type	Original e tipo.
Resource ID	ID usado em Inspect/Delete.
Scope / Session ID / Owner ID	Isolamento obrigatório na recuperação.
Fields / Record Count	Metadados para o receipt.
Allow Secret-Like Content	Autoriza storage de padrões sensíveis.
Storage Provider / Directory / Redis Prefix	Backend e namespace.
Encrypt Stored Content	AES-256-GCM autenticado.
Maximum Resource Size / TTL	Limites.
Output	Receipt simples ou manifesto detalhado.

6. Exact Lookup

O que faz

Tool do AI Agent para recuperar somente a parte exata necessária. Não injeta automaticamente o original inteiro.

Configuração do nó

Campo	Função
Tool Description	Diz ao Agent quando consultar; inclua “valores exatos ausentes”.
Storage Provider / Directory / Redis Prefix	Deve coincidir com o produtor.
Scope / Session ID / Owner ID	Deve coincidir; acesso cruzado é rejeitado.
Encrypted Storage	Usa a mesma chave do produtor.
Maximum Calls per Execution	Evita loop de recuperação.
Maximum Tokens per Execution	Orçamento total de recuperação.
Maximum Retrieval Tokens / Results	Limites por chamada.
Allowed / Blocked Fields	Política de exposição. Blocked prevalece.
Allow Full Original	Desligado por padrão; prefira busca/filtro/trecho.

Operações disponíveis ao Agent

search_context, filter_records, get_exact_value, get_section, inspect_schema e, se autorizado, get_original. A resposta informa Resource ID, path/trecho e se o valor é exato.

7. Savings Report

O que faz

Consolida economia estimada e uso real reportado pelo provider. Inclui Agent Optimizer, Data Optimizer, Agent Handoff, Session Memory, Context Storage e overhead do Exact Lookup.

Operações

Operação	Função
Current Execution	Recomendado; agrega automaticamente a execução atual.
Aggregate Items	Soma vários outputs recebidos.
Analyze Savings	Analisa um output normalizado.
Compare Current Model Calls (A/B)	Compara wrappers baseline/otimizado da mesma execução.
Compare Saved Runs	Compara métricas carregadas de execuções diferentes.
Estimate Cost	Aplica preços informados; não chama provider.

Campos

Campo	Função
Baseline / Optimized Model Wrapper	Nome exato dos nós no A/B.
Metrics / Baseline Metrics / Optimized Metrics	Objetos de telemetria.
Input / Cached Input / Output / Reasoning Price	Preço por 1 milhão de tokens.
Currency	Rótulo do custo.
Output	Simple mostra só decisão e números úteis; Detailed inclui diagnósticos.

`netSavedTokens` = original - enviado - compressor - verificação - recuperações. Usage do provider não é inventado: quando ausente, aparece como estimativa.

Configurações recomendadas

Agente comum

```
text
Agent Optimizer
Mode: Save Tokens
Profile: Balanced
Adaptive Quality Protection: On
Cache Strategy: Automatic Hybrid
```

Muitas tools

Use Maximum Savings com seleção automática, mínimo de 8 tools, máximo de 6 e nomes críticos em Always Available. Se a intenção for ambígua, todas permanecem.

JSON/tool output grande

Use Data Optimizer / Maximum Savings + Context Storage/Exact Lookup. Defina Current Task, proteja campos críticos e use Output Simple.

Vários agentes

Use Agent Handoff. Passe fatos, decisões, pendências e Resource IDs; não repasse o transcript completo.

Chat longo

Use Session Memory / Balanced. Envie apenas mensagens novas a Update Session; use memoryContext no Agent.

Segurança e qualidade

- Nunca coloque senha/API key no prompt para “economizar”; deixe secret-like storage desligado.
- Use Redis e criptografia para múltiplos workers/usuários.
- Mantenha Scope, Session ID, Owner ID, provider, prefix/path e chave iguais entre Storage e Lookup.
- Maximum Savings sem recuperação é rebaixado automaticamente quando a perda seria irreversível.
- Compare resposta baseline/otimizada com evals antes de ativar em produção.

Diagnóstico rápido

Sintoma	Correção
Economia 0%	Conteúdo curto, único, ambíguo ou protegido; veja <code>bypassReason</code> .
Perfil rebaixado	Veja <code>adaptiveReasons</code> ; conecte Exact Lookup ou remova requisito incompatível.
Resource not found	Confira TTL, backend, directory/prefix e Scope/Session/Owner.
Credencial Redis falha	Teste URL, usuário, senha, TLS <code>rediss://</code> e rede do worker.
Custo maior	Use Savings Report; compressor/retrieval pode superar ganho em entradas pequenas.

Validação local

```
bash
npm run check:local
npm run benchmark:v1
```

Workflows de laboratório:

- `examples/workflows/context-saver-v1-chat-first-message.workflow.json`
- `examples/workflows/context-saver-v1-local-runtime.workflow.json`

Eles usam somente dados fictícios e não chamam provider externo.